

프로젝트 결과 보고서_10조

철강 제조 공정 7종 표면 결함 다중 클래스 분류

철판 결함 예측 분석 모델 개발

CH.5 심화 프로젝트

Team

10

Team Name

10구만

Members

권대영, 김민경, 모상혁, 방귀현, 최지호

Tutor

임영재 튜터님

목차 Contents

01

프로젝트 개요

02

프로젝트 팀 구성 및 역할

03

프로젝트 수행 절차 및
방법

04

프로젝트 수행 경과

05

자체 평가 의견

원전 13기에서 방사성물질 누출 방지철판 결함, 노웅래 "대책 시급"

윤종학 기자 jhyoon@businesspost.co.kr | 2019-10-06 14:59:55



공유하기



방사성 물질의 누출을 막는 격납건물철판(CLP)에서 표면 부식과 변형 등의 결함이 발견된 원자력발전소가 13기나 되는 것으로 나타났다.

6일 노웅래 국회 과학기술정보방송통신위원회 위원장 겸 더불어민주당 의원이 원자력안전 위원회에서 받은 자료에 따르면 올해 7월21일 기준으로 원자력발전소 13기에서 모두 9998 곳의 격납건물철판 결함이 발견됐다.

격납건물철판은 일부 원전의 격납건물 내벽에 설치된 철판이다. 건설 당시 콘크리트 타설 거푸집 역할을 하며 방사선 누출 방지를 위한 기밀성 유지 기능도 한다.

국내 원전 가운데 19기가 격납건물철판을 쓰는 방식으로 건설됐다. 여기 들어가는 격납건물철판은 6mm 두께의 탄소강이어야 하며 만약 두께가 5.4mm 미만이면 교체나 보강 등 보수작업을 해야 한다.



▲ 노웅래 더불어민주당 의원(국회 과학기술정보방송통신위원장).

원자력안전위는 2016년 6월 한빛 2호기 정기검사 중 격납건물철판 부식을 확인했고 이후 전체 원전을 대상으로 점검을 진행해 왔다.

국내 운전 중 19기가 격납 건물 철판 사용
이러한 철판에 결함이 발생할 경우 방사선 누출
방지를 제대로 수행할 수 없음.

이러한 문제를 예방하기 위해서는 철판
결함의 유형을 **정확히 예측하는 모델링을**
개발하고, 결함이 발생하는 공정을
조사하여 해결방안을 제시해야 함.

프로젝트 주제 및 선정 배경

철판 결함 예측 머신러닝 모델 구축

철판 결함 데이터를 기반으로 결함 유형별 주요 특성을

분석하고,

머신러닝 모델을 활용해 결함을 자동 분류함으로써 사후 검출

중심의 품질관리에서 사전 예측 및 예방 중심이 품질관리로

전환할 수 있는 가능성을 확인해보고자 주제 선정

분석 목표 및 문제 정의

• 분석 목표

철판 제조 공정에서 발생하는 표면 결함 유형을 공정 및 품질

특성 데이터를 기반으로 자동 분류

• 문제 정의

공정 및 품질 지표 데이터를 활용하여 철판 표면 결함 유형을

사전에 분류하고, 결함 발생에 영향을 주는 주요 변수를 도출할

수 있는가?

주요 분석 포인트 및 기대 인사이트

POINT

결함 유형에 따른 관련 변수 분석 | 통계 검정 및 변수 중요도 분석 | 머신러닝 기반 결함 분류 모델 구축

이름	역할	담당 업무
방귀현 (팀장)	팀장 / 운영 총괄 / 모델2 모델링	일정 관리, 역할 조율, 회의 진행, 모델2 모델링 및 최종 제출물 점검
권대영	모델2 모델링	모델2 모델링, 모델 성능 개선 및 오분류 분석
김민경	시각화 / 인사이트 정리	데이터 시각화, 그래프 작성, 공정 개선 인사이트 및 핵심 메시지 정리
모상혁	데이터 전처리 / 모델1 모델링	데이터 구조 확인, 결측치 및 이상치 처리, 파생변수 생성, 모델1 모델링
최지호	데이터 전처리 / 모델1 모델링	데이터 구조 확인, 결측치 및 이상치 처리, 모델1 모델링, 발표 대본 및 흐름 구성

튜터 피드백 및 중간 점검 내역

임영재 튜터님

지원 내용 (피드백 / 멘토링)

결함별 주요 변수 선정 기준 보완, 불량률 해석 근거 구체화, 시각화별 메시지 명확화, 발표 흐름 정리



문제 정의

1일차



데이터 이해

2일차



데이터 전처리

3~4일차

EDA 및
시각화

4~6일차



모델 생성 및 결과 해석


7일차

상세 수행
활동

구분	기간	활동 내용	비고
문제정의	2026.04.29 ~ 04.29	프로젝트 주제 선정, 데이터셋 확보, 분석 목표 수립	
데이터 이해	2026.04.29 ~ 04.30	데이터 구조 파악, 변수별 분포 확인, 클래스 불균형 분석	
데이터 전처리	2026.04.30 ~ 05.04	극단값 탐지(박스플롯), 수동 이상치 제거(2건), 파생변수 12개 생성	
EDA 및 시각화	2026.05.04 ~ 05.06	상관관계 분석, 피처 중요도(MI Score), Confusion Matrix 시각화	
모델 생성 및 결과 해석	2026.05.06 ~ 05.08	모델 1, 2 성능 비교, 인사이트 도출, 결과보고서 작성	


데이터 구성

정보	내용	
출처	UCI Steel Plates Faults Dataset	
크기	행	1,941 개
	열	Features 27개 + targets 7개
변수	결함의 밝기	밝기 총합, 밝기 최댓값, 밝기 최솟값, 밝기 관련 종합 지표
	결함의 모양	결함의 경계 길이, 결함의 방향성, 결함의 빈 정도, 결함의 모양, 결함의 경계 길이/결함 면적 비율
	결함의 위치	결함 좌표, 위치 지표 로그값, 결함이 철판 바깥 경계에 가까운 정도
	결함의 면적	결함 면적(픽셀 기준), 결함 면적의 로그 변환값 및 시그모이드 변환값
	기타 변수	철판 이송 거리, 철판 두께, 강종 타입
결측치	0건 (없음)	




클래스 불균형

최대 vs 최소 클래스 약 12배 차이 → SMOTE 필요



높은 상관관계

TypeOfSteel A300/A400 상관계수 -1.0 → 다중공선성 제거 대상



- 통계적 기준(IQR)으로 일괄 제거 시, K_Scratch 클래스가 80% 이상 손실
- 수동으로 극단값만 선별 제거
- **1,941건 → 1,939건 (단 2건만 제거)**

- Feature Engineering

분류	파생변수	설명
기하학적	Width, Height, Area_Ratio, Aspect_Ratio, Perimeter_Area_Ratio	결함의 크기, 형태, 비율 특성 포착
밝기 관련	Luminosity_Range, Mean_Luminosity	결함 부위의 밝기 분포 및 편차 특성
위치 관련	X_Center, Relative_X	결함의 절대/상대 위치 정보
인덱스 조합	Edge_Square_Ratio, XY_Index_Product, Edge_XY_Sum	기존 인덱스 변수 간 상호작용 포착

- LabelEncoder 적용

: One-Hot 타겟을 단일 숫자 레이블로 변환 (XGBoost 호환)

- SMOTE 오버샘플링

: imblearn Pipeline 내 적용 (CV 폴드별)

- Y_Maximum 제거

: Y_Minimum + Height로 대체 가능

최종 피처 구성

원본: 27개 → 25개 (2개 제거)

파생: +12개 추가

최종: 37개 변수로 모델 학습

- 베이스라인 모델 파이프라인



- 베이스라인 모델 최종 성능

모델	Accuracy	F1-Macro	F1-Weighted
Random Forest	0.6889	0.7005	0.6874
ExtraTrees	0.6992	0.7080	0.6954
XGBoost	0.7018	0.7096	0.6988
LightGBM	0.6941	0.6950	0.6899
GradientBoosting	0.6941	0.7039	0.6920
Voting	0.6915	0.7012	0.6880
Stacking	0.6967	0.7133	0.6961

모델 1

- 박스플롯 기반 극단값 수동 제거(2건만 정밀 제거)
- DBSCAN 제거 → 수동 제거로 대체 (클래스 보존)
- 모델링 및 튜닝 파이프라인 적용 후 테스트셋을 통해 검증

모델 2

- Bumps와 Other_Faults 간 오분류가 다수 발생
- Other_Faults는 다양한 결함이 혼합된 클래스 특성으로 명확한 분류 어려움
- Other_Faults를 제외한 6개 결함 데이터만으로 모델 학습 및 분류 진행
- 데이터 전처리, 모델링 모델 1과 동일

Train/Test 분할

- 80:20 비율 (stratify=y)
- 클래스 비율 유지 분할
- random_state=42 고정

이상치 및 컬럼 처리

- 극단값 수동 제거
- 다중공선성 기반 컬럼 제거

오버샘플링

- SMOTE (k_neighbors=3)
- imblearn Pipeline 내 적용
- CV 폴드마다 train에만 적용

교차 검증

- Stratified 5-Fold CV
- 클래스 비율 유지
- 정보 누출(Data Leakage) 방지

모델 1

단일 모델 5종 + Optuna 하이퍼파라미터 튜닝 (150 trials/모델)


모델	Accuracy	F1-Macro	F1-Weighted	비고
GradientBoosting	0.8015	0.8413	0.8036	
Soft Voting	0.7964	0.8373	0.7992	5개 모델 확률 평균
LightGBM	0.7938	0.8197	0.7949	class_weight=balanced
XGBoost	0.7680	0.8148	0.7705	eval_metric=mlogloss
Random Forest	0.7655	0.8144	0.7688	class_weight=balanced
Stacking	0.7912	0.8124	0.7878	메타: LightGBM
ExtraTrees	0.7732	0.7986	0.7744	class_weight=balanced

Optuna 튜닝

- TPESampler (seed=42)
- 모델당 150 trials
- CV F1-Macro 기준 최적화

Stacking 앙상블



- Base: RF + ET + XGB + LGBM + GB
- Meta: LightGBM (lr=0.05, n=200)
- Stratified 5-Fold CV 기반 학습



- Bumps -> Other Faults 오분류: 18~19개


- Other Faults -> Bumps 오분류: 21~25개

→ 모델이 Bumps와 Other_Faults를 잘 구분하지 못함



PCA와 t-SNE 분석 결과,
Bumps와 Other Faults는 선형·비선형 관계 모두에서 군집이 크게 겹쳐 뚜렷한 경계가 형성되지
않음.

→ 결함 feature가 비슷해 구분이 어려운 것으로 추측




중요 변수들의 SHAP 값들이 높은값(빨간색)과 낮은 값(파란색)이 혼재하는 영역이 가운데 뭉쳐있음.

→ 예측 방향성이 일정하지 않으며,
모델 예측에 큰 영향을 주지 못함.

변수별 영향력이 한쪽 방향으로 치우쳐지지 않고

가운데(0)에 몰려있음

→ 대부분의 변수의 영향력이 크지 않음.



다른 결함들(왼쪽)은 기존 **feature**들로 명확히 구분이 되지만,

Bumps와 **Other Faults**(오른쪽)는 넓은 분포로 인한 노이즈로 인해 오분류 하는 것으로 파악

→ **Other Faults** 제외 후 분석 재실시 (모델2)

Train/Test 분할

- 모델 1과 동일
- 80:20 비율 (stratify=y)
- 클래스 비율 유지 분할
- random_state=42 고정

오버샘플링

- 모델 1과 동일
- SMOTE (k_neighbors=3)
- imblearn Pipeline 내 적용
- CV 폴드마다 train에만 적용

이상치 및 컬럼 처리

- Other_Faults 제거 후 6개 결함만 학습 진행
- 이상치 처리는 모델 1과 동일
- 극단값 수동 제거
- 다중공선성 기반 컬럼 제거

교차 검증

- 모델 1과 동일
- Stratified 5-Fold CV
- 클래스 비율 유지
- 정보 누출(Data Leakage) 방지

모델 2

단일 모델 5종 + Optuna 하이퍼파라미터 튜닝 (150 trials/모델)


모델	Accuracy	F1-Macro	F1-Weighted	비고
GradientBoosting	0.9370	0.9391	0.9374	
Soft Voting	0.9488	0.9464	0.9488	
LightGBM	0.9488	0.9495	0.9493	
XGBoost	0.9252	0.9175	0.9252	
Random Forest	0.9252	0.9206	0.9256	
Stacking	0.9291	0.9216	0.9275	
ExtraTrees	0.9449	0.9513	0.9451	

Optuna 튜닝

- TPESampler (seed=42)
- 모델당 150 trials
- CV F1-Macro 기준 최적화

Stacking 앙상블

- Base: RF + ET + XGB + LGBM + GB
- Meta: LightGBM (lr=0.05, n=200)
- Stratified 5-Fold CV 기반 학습




- 대다수의 결함들을 정확하게 분류
- Other_Faults 제외하여 분류 불가능

모델	모델 1 F1-Macro	모델 2 F1-Macro	변화
Random Forest	0.8144	0.9206	+0.1062
GradientBoosting	0.8413	0.9495	+0.1082
ExtraTrees	0.7986	0.9513	+0.1527
XGBoost	0.8148	0.9175	+0.1027
LightGBM	0.8197	0.9495	+0.1298
Voting	0.8373	0.9464	+0.1091
Stacking	0.8124	0.9216	+0.1092

핵심 인사이트

- 극단값 2건 수동 제거, 파생변수 12개 추가, SMOTE 적용 등 도메인 기반 전처리만으로 F1-Macro가 0.71 → 0.84로 향상.
모델 구조를 바꾸는 것보다 데이터 품질을 높이는 것이 더 큰 성능 개선 효과를 보임.
- PCA/t-SNE 분석 결과 Other_Faults는 다른 결함 유형과 피쳐 공간이 심하게 겹치는 "잡음 클래스"로 확인됨.
제외만으로 전 모델 F1-Macro가 평균 +0.11 향상(0.84 → 0.95)되었으며, 이는 분류 경계를 흐리게 하던 근본 원인이 제거되었음을 의미.
- Optuna 150 trials 튜닝 + 트리 기반 앙상블 조합에서 ExtraTrees가 F1-Macro 0.9513으로 최고 성능 기록. 랜덤 분할 기반의 ExtraTrees가 결함 간 미세한 피쳐 차이를 포착하는 데 가장 효과적.


결함별 주요 Features 및 결함 해결법 (Z-Scratch)



Length_of_Conveyer : 체류 시간이 길수록 roller와의 반복 접촉 및 표면 마찰 가능성 증가
→ Roller 접촉 최소화 및 transfer 안정화 필요

TypeOfSteel_A300 : 특정 강종에서 표면 마찰 민감도가 높아 Z_Scratch 분류 경향 증가 → 강종별 공정 조건 및 표면 품질 관리 강화

Steel_Plate_Thickness : 얇은 강판일수록 진동과 미세 마찰에 민감 → Thin plate 전용 roller alignment 및 conveyor 안정화 필요



Pixel Areas, log of Area : 해당 변수가 작을 경우 분류정도가 좋아짐. 이에 대해 대부분 **Stains**는 윤활유의 비산이나 미세 수분 응축에 의해 발생한걸로 추정할 수있음.


→ 윤활유의 분사를 균일화 하거나 **Surface cleaning** 실시

Perimeter_Area_Ratio : 해당 값이 큰 경우 복잡한 얼룩임을 의미. **Cleaning** 불균형과 번짐에 의해 **Stains**가 발생.

→ **Cleaning Uniformity** 개선, 강판 표면 모니터링

Sum_of_Luminosity : 밝기 총합이 낮을수록 표면에 오염층이나 산화층이 존재할 가능성이 높음


→ **Degreasing** 및 **anti-rust** 공정 강화, 표면 청정도 관리



Edges_Index : 값이 커질 수록, 경계가 복잡하고 거친 형태를 띠며, 이에 따라 표면 오염 축적 가능성 증가 → **Cleaning uniformity** 강화 필요

Aspect_Ratio : 값이 낮을수록 넓게 퍼진 flat 형태의 오염 패턴을 가짐. → **Surface cleaning** 및 **drying** 조건 최적화


Y_Minimum / Relative_X : 특정 위치 및 공정 구간에서 **Dirtiness** 집중 발생 경향 → 오염 위치 맵핑 및 특정 **zone** 집중 관리 필요



Perimeter_Area_Ratio : 값이 작을수록 길게 이어진 scratch 형태를 의미하며, 횡방향 반복 접촉 가능성을 시사 → **Roller alignment** 및 **side guide** 점검 필요

Steel_Plate_Thickness / Width : 얇은 강판은 진동에 민감하고, Width가 클수록 횡방향 힘이 넓게 전달된 손상 형태를 의미 → **Conveyor** 진동 관리 및 **centering** 강화

Edges_Y_Index: Y축 방향 경계 특성 증가 → 압연·냉각·장력 불균형 가능성 → **Rolling stability** 및 **Tension control** 강화 필요




Aspect_Ratio: 값이 낮을수록 넓게 퍼진 patch 형태 결함 → Cooling / 압연 압력 균일화 필요

Orientation_Index: 특정 방향성이 클수록 압연·장력 불균형 가능성 증가 → Roller 속도 및 좌우 balance 점검

Outside_X_Index: Edge 영역 집중 경향 → 가장자리 냉각 및 압력 편차 영향 가능 → Edge cooling / pressure control 강화

Length_of_Conveyer: 공정 체류 시간 변화가 냉각 및 처리 조건에 영향 → 병목 공정 및 transfer 조건 최적화

Edges_Y_Index: Y축 방향 경계 특성 증가 → 압연·냉각·장력 불균형 가능성 → Rolling stability 및 Tension control 강화



Bumps는 다른 결함들과 비교했을 때, 가로축(분류 성능)이 매우 나쁘게 나옴.

(다른 결함들과 비교했을 때 분류 정도가 낮음)


TypeOfSteel_A300: 특정 강종의 기계적 특성으로 인해 국부 변형 및 Bumps 발생 가능성 증가 → 강종별 공정 조건 최적화 및 표면 품질 관리 필요

Edge_XY_Sum: 경계가 확장된 불규칙한 돌기 형태일수록 국부 응력 집중 가능성 증가 → Rolling pressure 균일화 및 edge stress 관리 필요

Square_Index: 결함이 블록 형태의 국부 변형 패턴이 나타날수록 Bumps 분류 경향 증가 → Cooling uniformity 및 zone-based 압연 제어 강화

Length_of_Conveyer: 이송 과정 중 진동·반복 접촉 또는 공정 제어 조건 변화가 Bumps 형성에 영향 가능 → Transfer 안정성 주의

Y_Minimum: 특정 위치에서 반복적인 결함 발생 경향 확인 → Zone mapping 기반 설비 및 cooling zone 집중 점검 필요



Steel_plate_Thickness: Steel_plate의 두께가 큰 값에서는 분류가 잘됨. 그러나 **Other faults**에는 여러 **Sample**들이 혼재되어 있기 때문에 분류 성능이 좋다고 볼 수는 없음.
 특히 **roll mark, scabs, dents**등의 경우, **bump**와 매우 유사한 특성을 지니고 있음.

***roll mark:** 압연 롤 표면의 손상이 강판에 나타나는 결함
 ***scale:** 압연 과정에 스케일이 뜯겨 나가 얇은 막이 덮힌 결함 **scab**
 ***dents:** 장비 손상 또는 이물질로 인해 강판이 국부적으로 눌리거나 튀어 올라옴.



피드백 반영



BEFORE

개선 전

피드백 내용 / 문제
상황

결함별 주요 변수 선정 기준 보완, 불량률 해석 근거 구체화,
시각화별 메시지 명확화, 발표 흐름 정리



AFTER

개선 후

개선 결과 / 반영
내용

파생 변수 12개 생성 및 원본 데이터 최대한 활용,
시각적 자료 개선, 스토리텔링식 발표 구성



트러블 슈팅



문
제 (Problem)

Bumps와 Other_Faults 사이에서 오분류가 반복적으로 발생함



원
인 (Cause)

데이터 분석 결과 두 결함의 feature 특성이 상당히 유사하게
나타남



해
결 (Solution)

Other_Faults를 포함한 Model 1과 Other_Faults를 제외한
Model 2의 성능 비교 진행
-> Other_Faults 제외 후 전체 성능이 유의미하게 향상됨

프로젝트 결과물에 대한 프로젝트 기획 의도와의 부합 정도 및 실무 활용 가능 정도, 달성도, 완성도 등 개개인별로 자체적인 평가 의견을 느낀 점을 작성해주세요.



완성도 평가

이름	점수	평가 사유
권대영	8 / 10	다양한 문제들이 있었지만 여러가지 방법들을 시도해보며 모델의 성능을 개선할 수 있었음.
김민경	8 / 10	실무에 적용하기엔 아쉬운 점이 있지만 모델을 추가로 구축하여 성능을 개선할 수 있었음
모상혁	8 / 10	다양한 방식의 이상치 처리와 머신러닝 모델을 통해 모델 성능을 많이 개선하였음.
방귀현	9 / 10	많은 시행 착오가 있었지만 피드백을 적극적으로 반영해 주었기 때문에 프로젝트를 무사히 수행할 수 있었음.
최지호	8 / 10	처음에 생각하던 방향성과는 달라진듯한 느낌이 들기는 하지만, 해보려 하던 것들 모두 무사히 수행 할 수 있었음.



잘한 점

- 모델 성능을 위해 변수 분류, 이상치 제거, 모델링 과정에서 다양한 기법 활용
- 파생변수 생성, 주요 변수 재선정, 하이퍼파라미터 최적화 등을 통해 모델 성능 향상
- 단순 모델 성능 비교가 아닌, Confusion Matrix와 SHAP 분석을 통해 오분류 원인 해석
- 모델 1의 한계를 확인한 뒤 Other_Faults 제외 모델2를 추가로 구축하여 성능



아쉬운 점

- Other Faults는 여러 결함 특성이 섞여 있어 모델이 명확히 학습하기 어려웠고 분류 성능이 기대만큼 높게 나오지 않음.
- Other Faults를 제외하여 모델 성능은 개선되었지만, 실제 현장 적용을 위해서는 도메인적 지식과 추가 데이터가 필요
- 모델링 과정에서 많은 시간이 소요되어 불량 원인 추적 등 추가 프로젝트까지 진행하지 못함.

프로젝트 결과물에 대한 프로젝트 기획 의도와의 부합 정도 및 실무 활용 가능 정도, 달성도, 완성도 등
개개인별로 자체적인 평가 의견과 느낀 점을 작성해주세요.



느낀 점 / 성과



권대영

- 머신러닝 모델을 직접 구축해보며 이러한 모델들이 실제 산업의 다양한 분야에서 활용될 수 있다는 확신을 가지게 됨
- 제조 데이터의 경우 변수 간 관계가 명확하지 않은 경우가 많아 분석 시 도메인 지식의 필요성을 체감함



김민경

철강 도메인 지식과 머신러닝 경험이 부족해 어려움이 많았는데, 팀원들에게 도움을 많이 받아 EDA, 전처리, 모델링, 결과 해석까지 전체 분석 흐름을 경험할 수 있었다.



모상혁

다양한 방식의 데이터 전처리를 진행하며 전처리 방식에 따라 모델 성능이 바뀔 수 있다는 것을 알게 되었고, 모델을 돌리며 컴퓨터 cpu 성능의 중요성을 알게 되었음.



방귀현

- 가장 어려웠던 이상치 제거부터 모델링 활용까지 경험할 수 있어서 모델링과 데이터 분석과정에서 **Base line**의 중요성을 직접 익힐 수 있었음.
- 변수 선정과정과 파생변수를 만드는 과정에서 도메인 지식이 매우 중요하다는 것을 알 수 있었음



최지호

튜닝 알고리즘을 사용할 때 성능 극대화를 위해 많은 파라미터와 큰 범위의 값들을 추가하면 시간과 자원 소모량이 커져 좀 자제해야 할 필요가 있다는 것을 알게 되었음.
모델링 보다 전처리에 더 큰 비중을 두어야 한다는 것을 느꼈음.

개선점 / 보완점

튜닝남 퍼드백어나 향후 개선 방향을 작성하세요

1

Model 2는 Other_Faults를 분류할 수 없다는 한계가 존재해 향후 Other_Faults 내 세부 결함(roll mark, scabs, dents 등)에 대한 추가 데이터와 라벨 정보를 확보하여, Model 1과 Model 2의 장점을 결합한 상위 모델을 구축할 필요가 있음.

2

실제 품질 관리에 적용하기 위해서는 전체 결함 유형을 대상으로 한 추가 검증과 새로운 데이터에 대한 일반화 성능 평가가 필요함. 또한 딥러닝 모델들도 적용해서 추가적인 성능 개선이 필요함.

3

분리되지 않는 변수가 아닌 데이터의 구성을 먼저 파악할 필요가 있음.